

IES Abastos

Valencia

**MercaIntelligence: Sistema de
análisis, predicción y detección de
anomalías de precios sobre el
catálogo de Mercadona mediante
Big Data y Machine Learning**

Memoria del Proyecto de IA & Big Data

Daniel Porras Morales

Curso de Especialización de Inteligencia Artificial y Big Data

Memoria del Proyecto de IA & Big Data

IES Abastos. Curso 2025/26. Grupo 8IA. 28 de Mayo de 2026

Tutor/a: Mario Carbonell Izquierdo

ÍNDICE

ANEXO A. Comparativa detallada de métodos de detección de anomalías.....	3
A.1. Diseño del pipeline multi-modelo.....	3
A.2. Resultados globales.....	3
A.3. Z-Score Rolling: análisis detallado.....	4
A.4. Isolation Forest: análisis detallado.....	5
Validación manual de los 59 productos.....	5
A.5. Autoencoder LSTM: análisis detallado.....	6
Entrenamiento en Google Colab (GPU T4).....	6
Distribución bimodal del error de reconstrucción.....	7
Calibración del umbral.....	8
A.6. Análisis de complementariedad (Jaccard).....	8
Interpretación comparativa.....	9
ANEXO B. Análisis de equivalencias NLP — casos documentados.....	9
B.1. Diseño del pipeline de equivalencias semánticas.....	9
B.2. Resultados globales.....	10
B.2.1. Métricas de matching semántico.....	10
B.2.2. Métricas económicas.....	11
B.3. Proceso iterativo de refinamiento económico.....	11
Iteración 1: precio absoluto (versión inicial).....	11
Iteración 2: precio por unidad de medida.....	12
Iteración 3: filtro de misma unidad.....	12
Iteración 4: mínimo de variedad comercial (versión final).....	12
B.4. Patrón «Monopolio de Match»: diagnóstico y resolución.....	12
Caso ilustrativo: helados.....	13
B.5. Casos legítimos de alta brecha.....	14
B.5.1. Yogures líquidos: brecha mediana +190,7% (20 pares).....	14
B.5.2. Detergente y suavizante de ropa: brecha mediana +191,2% (13 pares).....	14
B.5.3. Arroz: ejemplo de match estándar.....	15
B.6. Limitaciones funcionales documentadas.....	16
B.6.1. Match semántico correcto, equivalencia funcional incorrecta: limpieza de vajilla 16	
B.6.2. Subcategorías con brechas extremas pero poco representativas.....	17
B.7. Validación cuantitativa de los filtros.....	18
Filtros evaluados y descartados.....	18
B.8. Síntesis y conclusión económica.....	19
ANEXO C. Análisis del modelo XGBoost — SHAP y walk-forward.....	19
C.1. Diseño del regresor y justificación del enfoque.....	19
Decisiones de diseño clave.....	20
C.2. Feature engineering.....	20
C.3. Resultados: XGBoost frente a baseline naive.....	21
C.3.1. Evaluación global.....	22

C.3.2. Explicación: la persistencia como predictor óptimo.....	22
C.3.3. Evaluación condicional: solo muestras con cambio real.....	22
C.4. Interpretabilidad: análisis SHAP.....	23
C.4.1. Importancia global.....	23
C.4.2. Análisis beeswarm: impacto por valor de feature.....	24
C.4.3. Validación cruzada entre modelos: convergencia no planificada.....	24
C.5. Walk-forward validation.....	24
C.5.1. Diseño de la validación.....	24
C.5.2. Resultados por fold.....	25
C.5.3. Degradación temporal: conexión con el Autoencoder de anomalías.....	25
C.6. Observaciones técnicas del entrenamiento.....	26
C.6.1. Convergencia por early stopping.....	26
C.6.2. Hiperparámetros de regularización.....	26
C.7. Limitaciones del modelo.....	27
C.8. Síntesis y contribuciones del módulo.....	27
ANEXO D. Análisis del clustering K-Means — perfiles de negocio.....	28
D.1. Diseño del pipeline de segmentación.....	28
Decisiones de diseño clave.....	28
D.2. Feature engineering.....	29
D.3. Proceso iterativo de refinamiento.....	30
Iteración 1: entrenamiento crudo.....	30
Iteración 2: eliminación de outliers (percentil 99).....	30
Iteración 3: transformación logarítmica.....	30
Iteración 4: selección de K=5 (versión final).....	30
D.4. Métricas globales del modelo.....	30
D.5. Perfiles de negocio descubiertos.....	31
D.5.1. Cluster 3 — Frescos de Alta Volatilidad (30 productos).....	31
D.5.2. Cluster 2 — Básicos Estables de Marca Blanca (2.942 productos).....	31
D.5.3. Cluster 1 — Marcas Nacionales en Promoción (120 productos).....	32
D.5.4. Cluster 4 — Dinámicos de Variabilidad Moderada (490 productos).....	32
D.5.5. Cluster 0 — Estables de Precio Medio (1.467 productos).....	33
D.6. Diagnóstico visual.....	33
D.6.1. Método del codo y Silhouette Score.....	33
D.6.2. Proyección PCA 2D.....	34
D.6.3. Silhouette plot.....	34
D.7. Conexiones inter-modulares.....	34
D.8. Limitaciones del modelo.....	35
D.9. Síntesis y conclusión.....	35

ANEXO A. Comparativa detallada de métodos de detección de anomalías

A.1. Diseño del pipeline multi-modelo

El sistema implementa tres detectores que atacan el problema de la anomalía desde dimensiones matemáticas distintas. Esta decisión de diseño se tomó deliberadamente para maximizar la cobertura y demostrar que los métodos no son redundantes.

Modelo	Dimensión analizada	Parámetros clave	Justificación
Z-Score Rolling	Temporal (univariante)	Ventana=14d, umbral= $2,5\sigma$	Baseline estadístico. Detecta cambios bruscos de precio locales. El umbral de $2,5\sigma$ reduce falsos positivos en series estables.
Isolation Forest	Espacial (multivariante)	200 estimadores, contam=0,5%	Evalúa 5 features simultáneamente. La tasa del 0,5% se alinea con el Z-Score para comparabilidad.
Autoencoder LSTM	Secuencial (Deep Learning)	Ventana=14d, umbral=P99	Aprende de secuencias sin variación y falla al reconstruir secuencias anómalas. El umbral P99 equipara la rigurosidad.

A.2. Resultados globales

Método	Evaluidas	Anomalías	Tasa	Productos afectados
Z-Score Rolling (14d, 2,5 σ)	763.435	3.813	0,50%	1.683
Isolation Forest (200 árboles, contam=0,5%)	763.435	3.818	0,50%	59
Autoencoder LSTM (ventana=14d, P99)	692.816	6.929	1,00%	1.300

Nota: el Autoencoder evalúa secuencias temporales completas (ventanas de 14 días) en lugar de observaciones individuales, por lo que el número total evaluado es ligeramente menor.

A.3. Z-Score Rolling: análisis detallado

El Z-Score Rolling funciona como un detector de eventos temporales puntuales. Al usar una ventana deslizante de 14 días, se adapta a la inflación o deflación progresiva, marcando únicamente subidas o bajadas drásticas.

Distribución por categorías:

Categoría	Anomalías
Fruta y verdura	705
Agua y refrescos	441
Bodega	389
Cuidado facial y corporal	247
Marisco y pescado	190

Distribución por marca:

Marca	Anomalías
Comercial	2.789
Hacendado	757
Deliplus	187
Bosque Verde	54
Compy	26

El comportamiento es coherente: las anomalías se concentran en categorías con precios volátiles (fruta, marisco) y en marcas comerciales, cuyas estrategias de pricing incluyen promociones y ajustes frecuentes. Cada producto afectado presenta una media de ~2,3 anomalías, lo que indica una distribución amplia y no concentrada.

A.4. Isolation Forest: análisis detallado

El hallazgo más llamativo del Isolation Forest es la hiper-concentración: **3.818 anomalías en solo 59 productos** (~65 anomalías/producto). Esto significa que IF no detecta cambios puntuales de precio, sino productos que son **estructuralmente raros** de forma consistente.

Distribución por categorías:

Categoría	Anomalías
Charcutería y quesos	1.442
Limpieza y hogar	406
Congelados	341
Marisco y pescado	295
Cuidado facial y corporal	286

Validación manual de los 59 productos

Se investigaron manualmente los 59 productos flagelados para determinar si representan outliers legítimos o sobreajuste del modelo. El resultado confirmó que el 87,5% son productos con un `ratio_vs_media_subcat` superior a 2 (cuestan más del doble que la media de su subcategoría):

Perfiles dominantes identificados:

Perfil	Ejemplo	Precio	Ratio vs subcategoría
Ibéricos premium (~20 prod.)	Jamón bellota ibérico 100% Covap	504€	9,11×
	Lomo bellota ibérico Juan del Roble	98,80€	11,04×
Productos caros en cat. baratas	Cochinillo asado	50€	8,86×
	Cloro piscina tabletas	31€	4,06×
	Cepillo Oral-B recambios	14,50€	5,21×
Alimentación especializada	Leche Nidina Nestlé	~16€	3-4×

Distribución del ratio:

Rango del ratio	Productos	%	Interpretación
ratio > 2 (caros)	56	87,5%	Productos premium en subcategorías baratas
ratio < 0,5 (baratos)	6	9,4%	Formatos económicos (ej. jamón ibérico en lonchas vs entero)

Conclusión de la validación: Isolation Forest NO sobreajusta. Identifica exactamente lo que debería: productos cuyo perfil de precio es estructuralmente atípico dentro de su subcategoría. Son outliers legítimos, no falsos positivos.

A.5. Autoencoder LSTM: análisis detallado

Entrenamiento en Google Colab (GPU T4)

El entrenamiento se realizó en Google Colab debido a la limitación de TensorFlow ≥ 2.11 en Windows nativo (sin soporte GPU). La máquina de desarrollo local dispone de una GPU

NVIDIA GTX 960 con solo 2 GB de VRAM, insuficiente para Deep Learning moderno. Google Colab proporciona GPUs T4 con 16 GB de VRAM de forma transparente.

Parámetro de entrenamiento	Valor
Secuencias normales de entrenamiento	642.396
Ventana temporal	14 días
Features de entrada	3 (precio_actual_norm, variacion_pct, dias_sin_cambio_norm)
Encoder	LSTM 64 → LSTM 32
Decoder	LSTM 32 → LSTM 64
Parámetros totales	63.171
Convergencia	Época 18 (early stopping en 23)
MSE entrenamiento	$1,2790 \times 10^{-6}$
MSE validación	$2,7779 \times 10^{-8}$

Distribución bimodal del error de reconstrucción

Al evaluar las 692.816 secuencias totales, la distribución del error de reconstrucción resultó bimodal:

Estadístico	Valor
Media	0,00517
Desviación típica	0,02352
P90	0,00000023
P95	0,03627
P99	0,1410
Máximo	0,1984

El dato clave es que el **P90 es menor que la media**: esto es imposible en una distribución normal y confirma la bimodalidad. El 90% de las secuencias (precios estables) tienen error ≈ 0 , mientras que la cola derecha corresponde a secuencias con cambios reales de precio.

Calibración del umbral

Percentil	Anomalías	Tasa	Valoración
P90	69.282	9,99%	Demasiado permisivo
P95	34.641	5,00%	Alto pero justificable
P99	6.929	1,00%	Seleccionado — comparable con ZS e IF

Se seleccionó el P99 por coherencia metodológica: dado que Z-Score e Isolation Forest operan al 0,5%, una tasa del 1% para el Autoencoder es la más cercana y sigue siendo selectiva. La justificación técnica es que el Autoencoder evalúa secuencias (692.816) y no observaciones individuales (763.435), por lo que una tasa ligeramente superior es equivalente en términos absolutos.

Distribución por categorías:

Categoría	Anomalías
Cuidado facial y corporal	768
Bodega	611
Agua y refrescos	566
Cuidado del cabello	462
Charcutería y quesos	425

A.6. Análisis de complementariedad (Jaccard)

El índice de Jaccard mide el solapamiento entre dos conjuntos: $J(A,B) = |A \cap B| / |A \cup B|$. Un Jaccard de 1 indica conjuntos idénticos; un Jaccard de 0 indica conjuntos completamente disjuntos.

Par comparado	Detectados por ambos	Solo por método A	Solo por método B	Jaccard
Z-Score ↔ IF	34	3.779	3.784	0,006
Z-Score ↔ AE	0	3.813	6.929	0,000

Par comparado	Detectados por ambos	Solo por método A	Solo por método B	Jaccard
IF ↔ AE	33	3.785	6.896	0,005

Interpretación comparativa

Método	Qué detecta	Perfil típico de anomalía
Z-Score	Cambios bruscos de precio en un producto a lo largo del tiempo	Subida/bajada repentina de precio por promoción, ajuste o error
Isolation Forest	Productos con perfil de precio estructuralmente raro en el espacio multidimensional	Producto premium en subcategoría barata (jamón ibérico, cochinillo)
Autoencoder LSTM	Rupturas en el patrón secuencial aprendido	Secuencia de 14 días que no encaja con el comportamiento estable aprendido

La complementariedad extrema (Jaccard ≈ 0) es el resultado más sólido del módulo de anomalías: confirma que los tres métodos no son redundantes, sino que capturan dimensiones completamente ortogonales del comportamiento anómalo. Esto justifica su uso combinado para una cobertura robusta del catálogo.

ANEXO B. Análisis de equivalencias NLP — casos documentados

B.1. Diseño del pipeline de equivalencias semánticas

El módulo de equivalencias utiliza el modelo preentrenado *paraphrase-multilingual-MiniLM-L12-v2* de la librería *sentence-transformers* para generar embeddings de 384 dimensiones y detectar productos funcionalmente equivalentes entre marcas. El pipeline opera en cinco fases secuenciales: carga del catálogo, generación de embeddings, cálculo de similitud coseno por subcategoría, resumen estadístico y exportación de resultados.

Las decisiones de preprocesamiento y filtrado se tomaron de forma iterativa durante el desarrollo, resolviendo sesgos detectados en cada versión. La siguiente tabla documenta las siete decisiones de diseño que configuran la versión final del sistema:

Decisión	Justificación
Eliminar la marca del título antes de generar embeddings	Evita que la similitud coseno mida afinidad de marca en lugar de similitud de producto. Sin esta corrección, «leche Hacendado» tendría mayor similitud con «yogur Hacendado» que con «leche Puleva».
Concatenar el formato al título	Distingue SKUs con el mismo nombre pero diferente envase (ej. Leche 1L frente a Leche Pack 6×1L), evitando colisiones en el espacio de embeddings.
Restricción por subcategoría	Impide falsos matches inter-categoría (ej. «leche» ↔ «yogur» por compartir vocabulario lácteo).
normalize_embeddings=True	Permite calcular la similitud coseno como producto escalar, mejorando el rendimiento computacional sin pérdida de precisión.
TOP_K=3 con umbral mínimo de 0,75	Doble filtro: ranking por proximidad y mínimo de calidad semántica. Solo se conservan los matches con alta similitud.
MIN_COMERCIALES=3	Exige al menos 3 productos comerciales por subcategoría, eliminando el patrón de «monopolio de match» (§B.4).
Filtro misma_unidad	Solo calcula la brecha de precio por medida cuando ambos productos comparten la misma unidad (€/kg con €/kg, €/L con €/L), evitando comparaciones absurdas entre magnitudes incompatibles.

B.2. Resultados globales

B.2.1. Métricas de matching semántico

Métrica	Valor
Productos en catálogo	4.312
Marca propia	2.858

Métrica	Valor
Marca comercial	1.454
Equivalencias top-1	924
Cobertura (top-1 / marca propia)	32,3%
Similitud media	0,844
Similitud mínima	0,750

Una similitud media de 0,844 con un modelo multilingüe sobre textos cortos en español constituye un resultado sólido que confirma la capacidad del modelo para capturar la semántica del dominio de productos de supermercado.

B.2.2. Métricas económicas

Métrica	Valor
Pares comparables (misma unidad)	892 de 924 (32 excluidos)
Precio medio por medida — marca propia	5,23 €/medida
Precio medio por medida — marca comercial	7,21 €/medida
Brecha mediana (por medida)	+49,0%
Brecha media (por medida)	+82,6%

Se utiliza la mediana (+49,0%) como estadístico principal por su robustez frente a outliers. La media (+82,6%) es más elevada por la influencia de subcategorías con grandes primas de marca legítimas (cosmética, detergentes).

B.3. Proceso iterativo de refinamiento económico

El cálculo de la brecha de precios pasó por cuatro iteraciones antes de alcanzar la versión final. Cada iteración resolvió un sesgo específico detectado en la anterior. Esta transparencia metodológica se considera una fortaleza del análisis, ya que demuestra el razonamiento crítico aplicado durante el desarrollo.

Iteración 1: precio absoluto (versión inicial)

Brecha media: +73,2%

Sesgo detectado: comparar precios absolutos (€) distorsiona las brechas cuando los formatos son distintos. Un pack de 6 unidades de marca propia cuesta más que una unidad suelta de marca comercial, pero por unidad es más barato. En el caso de productos de alimentación animal, la brecha aparecía como -60% (marca propia aparentemente más cara), un artefacto de comparar un formato grande con uno pequeño.

Iteración 2: precio por unidad de medida

Brecha media: +173,5%

Sesgo detectado: al usar directamente el campo `precio_por_medida`, se comparaban unidades incompatibles. Solo 53 de 882 pares (6%) tenían unidades distintas, pero generaban la práctica totalidad de los outliers extremos:

Combinación de unidades	Pares	Brecha media
L frente a kg	13	+762%
100 g frente a kg	6	+1.017%
ud frente a L	1	+23.100%

Iteración 3: filtro de misma unidad

Brecha media: +80,3%

Brecha mediana: +45,6%

Sesgo detectado: persistían anomalías causadas por subcategorías con muy pocos productos comerciales (1-2), donde todos los productos de marca propia se emparejaban con el mismo producto comercial, a menudo uno premium o atípico.

Iteración 4: mínimo de variedad comercial (versión final)

Brecha media: +82,6%

Brecha mediana: +49,0%

Con `MIN_COMERCIALES=3`, se eliminan las subcategorías sin variedad suficiente. La mediana sube de +45,6% a +49,0% porque los pares eliminados eran los de «monopolio de match» (§B.4) que distorsionaban la distribución hacia abajo.

B.4. Patrón «Monopolio de Match»: diagnóstico y resolución

Se identificó un patrón recurrente en múltiples subcategorías: cuando solo existen 1-2 productos comerciales, todos los productos de marca propia se emparejan con ese único producto, generando brechas artificiales. El match semántico es técnicamente correcto (los textos comparten vocabulario), pero la falta de variedad comercial impide encontrar equivalentes funcionales adecuados.

Subcategoría	Productos comerciales	Producto único	Efecto sobre la brecha
Helados	1	Cucurucho fresa nata (3,40 €/L)	-40% a +79% (falsa inversión)
Mantequilla	1	Flora Proactiv (14,18 €/kg)	+122% a +389% (inflada)
Sal	1	Escamas Polasal (16,00 €/kg)	+3.900% (inflada)
Otras salsas	1	Salsa de trufa (38,75 €/kg)	+225% (inflada)

Caso ilustrativo: helados

Los 22 helados Hacendado se emparejaban con un único producto comercial — «helado cucurucho fresa nata» a 3,40 €/L — porque es el único helado de marca comercial en el catálogo. Los helados tipo bombón (chocolate, almendras) cuestan 7-8 €/L, no porque sean más caros que la marca comercial, sino porque son productos de gama superior comparados con un cucurucho básico:

Producto Hacendado	€/L marca propia	€/L marca comercial	Brecha
Bombón doble chocolate	8,55	3,40	-60%
Bombón almendrado	7,24	3,40	-53%
Cucurucho choco nata	3,40	3,40	0%
Helado de vainilla	2,40	3,40	+42%
Barra 3 sabores	1,90	3,40	+79%

El diagnóstico es claro: el match semántico es correcto («helado» ↔ «helado»), pero sin variedad comercial no existen equivalentes funcionales adecuados. Todos estos casos se eliminan sistemáticamente con el filtro $MIN_COMERCIALES \geq 3$.

B.5. Casos legítimos de alta brecha

Tras aplicar todos los filtros, se investigaron las subcategorías con mayor brecha mediana para separar las anomalías de los insights de negocio reales. Dos subcategorías destacan por la excelente calidad del matching y la nitidez de la brecha económica.

B.5.1. Yogures líquidos: brecha mediana +190,7% (20 pares)

Esta subcategoría ofrece una de las equivalencias semánticas y de negocio más limpias del catálogo. El modelo asocia perfectamente las variantes funcionales equivalentes: L-Casei ↔ Actimel (probióticos) y Cuidacol ↔ Danacol (control del colesterol).

Hacendado (marca propia)	Danone (marca comercial)	Similitud	€/L MP	€/L COM	Brecha
L-Casei Natural 0% mg	Actimel Natural 0% mg	0,985	2,17	4,99	+130,4%
L-Casei Fresa 0% mg	Danacol Fresa 0% mg	0,980	2,17	5,45	+151,5%
Cuidacol Fresa 0% azúcares	Danacol Fresa 0% mg	0,963	3,13	5,45	+74,4%
Cuidacol Natural 0% azúcares	Actimel Natural 0% mg	0,961	3,13	4,99	+59,7%

Las similitudes superiores a 0,96 confirman que el modelo captura con precisión los matices funcionales (sabor, composición, beneficio de salud). La brecha de hasta +151,5% por litro constituye un insight de alto valor para el consumidor: la alternativa de marca comercial cuesta más del doble que la de marca propia para el mismo beneficio percibido.

B.5.2. Detergente y suavizante de ropa: brecha mediana +191,2% (13 pares)

Todos los pares de esta subcategoría comparan Bosque Verde con Ariel, utilizando como unidad de medida el €/lavado, que es la métrica de dosis correcta para detergentes. Las similitudes superan 0,89 en todos los casos.

Bosque Verde	Ariel	€/lavado BV	€/lavado Ariel	Brecha
Det. prendas delicadas	Ariel líquido	0,038	0,265	+597%
Det. frescura	Ariel líquido	0,068	0,265	+290%
Det. de color líquido	Ariel líquido	0,096	0,265	+176%
Det. blanca y color cápsulas	Ariel Pods	0,194	0,384	+98%
Det. oscura líquido	Ariel líquido	0,134	0,265	+98%

La brecha oscila entre 2× y 7× el coste por lavado. Estos son insights genuinos que reflejan el posicionamiento premium del fabricante de marca comercial en productos de limpieza química, donde la percepción de calidad y la inversión publicitaria justifican márgenes elevados.

B.5.3. Arroz: ejemplo de match estándar

El arroz constituye el ejemplo de match directo más limpio del catálogo: misma unidad (€/kg), misma categoría y productos plenamente intercambiables sin sesgo por formato de envase.

Hacendado (marca propia)	Marca comercial	Similitud	€/kg MP	€/kg COM	Brecha
Arroz redondo	Arroz redondo La Fallera	0,954	1,20	1,69	+40,8%
Arroz largo	Arroz redondo La Fallera	0,938	1,25	1,69	+35,2%
Arroz redondo J. Sendra	Arroz redondo La Fallera	0,936	1,60	1,69	+5,6%

Hacendado (marca propia)	Marca comercial	Similitud	€/kg MP	€/kg COM	Brecha
Arroz basmati aromático	Arroz redondo sabor La Cigala	0,919	2,10	2,45	+16,7%

La brecha del +40,8% para el arroz redondo básico (Hacendado a 1,20 €/kg frente a La Fallera a 1,69 €/kg) con una similitud de 0,954 representa el caso canónico de equivalencia: producto intercambiable, unidad comparable y brecha moderada y creíble.

B.6. Limitaciones funcionales documentadas

B.6.1. Match semántico correcto, equivalencia funcional incorrecta: limpieza de vajilla

Este es el caso más representativo de las limitaciones inherentes al matching por texto. Cinco de los siete productos de «lavavajillas a mano» de Bosque Verde se emparejan con «limpiamáquinas lavavajillas Finish» (15 €/L), un producto de mantenimiento de la máquina que es funcionalmente distinto.

Producto marca propia	Producto marca comercial	€/L MP	€/L COM	Brecha	Diagnóstico
Lavavajillas a mano BV	Limpiamáquinas Finish	0,96	15,00	+1.459%	Incorrecto
Lavavajillas ultra concentrado BV	Limpiamáquinas Finish	1,83	15,00	+718%	Incorrecto
Lavavajillas aloe concentrado BV	Limpiamáquinas Finish	1,80	15,00	+733%	Incorrecto
Abrillantador lavavajillas BV	Abrillantador Finish	1,60	9,88	+517%	Correcto

Producto marca propia	Producto marca comercial	€/L MP	€/L COM	Brecha	Diagnóstico
Limpíamáquina s lavavajillas BV	Limpíamáquinas Finish	6,20	15,00	+142%	Correcto
Lavavajillas gel máquina BV	Somat gel 5en1	0,10	0,14	+49%	Correcto

El NLP acierta semánticamente: «lavavajillas a mano» y «limpiamáquinas lavavajillas» comparten la palabra «lavavajillas». Sin embargo, son productos funcionalmente diferentes con precios incomparables. Los tres pares correctos (abrillantador, limpiamáquinas, gel máquina) muestran brechas entre +49% y +517%, más coherentes con la realidad del mercado.

Esta limitación es inherente al matching por texto sin supervisión y se documenta como tal. Se propone como línea de mejora futura la incorporación de un clasificador supervisado ligero que, a partir de pares etiquetados manualmente, filtre los matches semánticamente correctos pero funcionalmente incorrectos (sección 4.4 de la memoria).

B.6.2. Subcategorías con brechas extremas pero poco representativas

Dos subcategorías presentan brechas elevadas con validez parcial pero sin representatividad estadística:

Subcategoría	Brecha mediana	Pares	Valoración
Limpieza muebles y multiusos	+258,1%	2	Brecha real (Bosque Verde básico frente a Pronto premium), pero solo 2 pares: insuficiente para generalizar.
Harina y preparado repostería	+178,3%	2	Mixta: el par impulsor Hacendado (7,78 €/kg) ↔ impulsor Royal (28,13 €/kg) con brecha de +261,6% es impecable; el par

Subcategoría	Brecha mediana	Pares	Valoración
			harina de garbanzo ↔ masa filo es un match funcional incorrecto.

B.7. Validación cuantitativa de los filtros

La siguiente tabla compara la distribución de calidad antes y después de aplicar los filtros metodológicos (*misma_unidad* y *MIN_COMERCIALES* ≥ 3), cuantificando su impacto sobre la pureza del dataset:

Métrica	Antes de filtros	Con filtros (versión final)
Pares comparables (misma unidad)	829	892
Cuartil 25%	+1,5%	+3,7%
Cuartil 50% (mediana)	+45,6%	+49,0%
Cuartil 75%	+115,2%	+108,7%
Pares en rango razonable (-50% a +200%)	715 de 829 (86,2%)	791 de 892 (88,7%)
Pares con brecha extrema (> 200%)	68 (8,2%)	62 (7,0%)
Pares con brecha negativa (< -50%)	46 (5,5%)	39 (4,4%)

La aplicación de los filtros incrementó el volumen neto de pares comparables (al refinar el catálogo activo), aumentó el porcentaje de pares en rango razonable del 86,2% al 88,7% y redujo la proporción de brechas extremas erróneas del 8,2% al 7,0%. Esto confirma cuantitativamente que la restricción de dominio por variedad comercial purifica el dataset de anomalías sin sacrificar información útil.

Filtros evaluados y descartados

Se evaluaron y rechazaron dos propuestas de filtrado adicional por las razones siguientes:

Filtro por palabras conflictivas (listas de pares incompatibles como «lavavajillas» / «limpiamáquinas»). Se descartó por ser ad-hoc y no generalizable. Además, puede eliminar matches legítimos: el par «salsa fresca trufa Hacendado» ↔ «salsa de trufa» tiene similitud 0,959 y es un match correcto que contiene ambas palabras potencialmente conflictivas.

Filtro por brecha superior al 300%. Se descartó porque eliminaría insights legítimos junto con los errores. El par «detergente prendas delicadas Bosque Verde frente a Ariel» con brecha de +597% es un insight genuino; el par «lavavajillas a mano frente a limpiamáquinas Finish» con brecha de +1.459% es un error. Un filtro ciego no distingue entre ambos, y la mediana como estadístico principal ya absorbe los outliers sin sacrificar información.

B.8. Síntesis y conclusión económica

El pipeline produce **924 equivalencias semánticas** con una similitud media de **0,844**, de las cuales **892 son directamente comparables** por precio por unidad de medida. El 88,7% de los pares se sitúa en un rango de brecha razonable (-50% a +200%).

La conclusión económica principal, sustentada por los filtros de calidad implementados:

La marca comercial es, en mediana, un 49,0% más cara por unidad de medida que su equivalente de marca propia, calculado sobre 892 pares con similitud semántica $\geq 0,75$, misma unidad de medida y mínimo de 3 productos comerciales por subcategoría.

Los tres filtros metodológicos — misma unidad de medida, mínimo de variedad comercial y mediana como estadístico de centralidad — garantizan que esta cifra sea robusta frente a los sesgos documentados en las secciones anteriores. Las limitaciones remanentes (equivalencia semántica frente a equivalencia funcional, granularidad de subcategoría) se reconocen con transparencia y se proponen como líneas de mejora futura.

ANEXO C. Análisis del modelo XGBoost — SHAP y walk-forward

C.1. Diseño del regresor y justificación del enfoque

El módulo de predicción de precio futuro implementa un regresor XGBoost que estima el precio de cada producto a un horizonte de 7 días. Se seleccionó XGBoost sobre alternativas clásicas de series temporales (ARIMA, Prophet) porque los precios de Mercadona no siguen patrones estacionarios: presentan una estructura de «escalón» donde permanecen constantes durante semanas o meses y cambian de forma discreta e impredecible. Los árboles de decisión son insensibles a esta estructura sin necesidad de transformaciones previas.

El sistema de predicción se articula como un ensemble de dos modelos independientes con roles complementarios:

Modelo	Tarea	Tipo	Pregunta que responde
LSTM (Sprint 3)	Clasificación binaria	Deep Learning	¿Habrà cambio de precio en los próximos 7 días?

Modelo	Tarea	Tipo	Pregunta que responde
XGBoost (Sprint 4)	Regresión sobre precio	Gradient Boosting	¿Cuánto costará el producto dentro de 7 días?

El horizonte de 7 días se fijó por coherencia con el LSTM clasificador, de modo que ambos modelos sean directamente comparables y combinables. La probabilidad de cambio generada por el LSTM (`prob_cambio_lstm`) se integra como feature del XGBoost, creando un flujo de información unidireccional entre ambos modelos.

Decisiones de diseño clave

Decisión	Justificación
Split temporal estricto (80/20)	Evita la fuga de información temporal. Los mismos productos aparecen en entrenamiento y test por diseño, ya que el objetivo es predecir precios futuros de productos existentes, no de productos nuevos.
Early stopping con validación interna	El 15% final del conjunto de entrenamiento se reserva como validación para detener el entrenamiento cuando el modelo deja de mejorar, evitando sobreajuste.
21 features en 5 familias	Combinación de features temporales (lags, rolling), contextuales (días desde cambio), del producto (categoría, marca), de calendario (día/mes) y del LSTM (probabilidad de cambio).
Baseline naive como referencia obligatoria	Comparación contra el predictor trivial <code>predicción = precio_actual</code> , imprescindible para cuantificar el valor real del modelo.

C.2. Feature engineering

Se construyen 21 features organizadas en cinco familias:

Familia	Features	Descripción
Lags de precio	precio_lag_1, lag_3, lag_7, lag_14, lag_30	Precio del producto hace N días — los predictores más directos.
Estadísticas rolling	media_7d, std_7d, media_14d, std_14d, min_14d, max_14d	Estadísticas de ventana deslizante que capturan nivel y volatilidad reciente.
Contexto temporal	tendencia_14d, dias_desde_cambio, n_cambios_total	Pendiente reciente y frecuencia histórica de cambios del producto.
Producto	precio_por_medida, categoria_enc, marca_enc, es_marca_propia	Características estáticas del producto.
Calendario	dia_semana, mes	Estacionalidad potencial.
LSTM	prob_cambio_lstm	Probabilidad de cambio predicha por el modelo LSTM independiente.

La integración del LSTM se realiza mediante un merge por referencia y fecha. Cuando no existe predicción LSTM para un par (referencia, fecha), se imputa `prob_cambio_lstm = 0,0` — equivalente a «sin indicación de cambio» —, lo que permite que el pipeline funcione de forma independiente.

C.3. Resultados: XGBoost frente a baseline naive

La evaluación se realizó sobre la siguiente partición temporal:

Parámetro	Valor
Muestras totales con features	547.720
Partición de entrenamiento	437.053 muestras (hasta el 17 de abril de 2026)
Partición de test	110.667 muestras (desde el 17 de abril de 2026)

C.3.1. Evaluación global

Métrica	XGBoost	Baseline naive	Diferencia
MAE (€)	0,1304	0,0230	Naive 5,7× mejor
RMSE (€)	4,7682	0,4210	Naive 11,3× mejor
R ²	0,7993	0,9984	Naive superior
MAPE (%)	1,29%	0,46%	Naive superior

El baseline naive supera ampliamente a XGBoost en todas las métricas globales. Este resultado no constituye un fallo del modelo, sino una propiedad fundamental del dominio que debe interpretarse correctamente.

C.3.2. Explicación: la persistencia como predictor óptimo

Los precios de Mercadona presentan una estructura temporal de «escalón»: permanecen constantes durante semanas o meses y cambian de forma discreta. En el conjunto de test, **el 95,9% de las muestras no presenta cambio de precio** en el horizonte de 7 días.

En este tipo de serie, el predictor de persistencia (`precio_mañana = precio_hoy`) es correcto por definición el 95,9% del tiempo. Cualquier modelo que intente aprender patrones más complejos introduce ruido en ese 95,9% de casos estables, degradando el rendimiento global. Este fenómeno es análogo a la eficiencia de mercado en finanzas: cuando los precios son «justos» y no cambian sin razón, predecir «sin cambio» es la estrategia dominante. La aportación de un modelo predictivo solo puede medirse en los casos donde el mercado sí se mueve.

C.3.3. Evaluación condicional: solo muestras con cambio real

Para cuantificar el valor real del modelo, se evalúa exclusivamente el subconjunto donde el precio futuro difiere del actual — es decir, donde la persistencia falla por definición (4,1% del conjunto de test, equivalente a 4.517 muestras):

Métrica	XGBoost	Naive	Mejora XGBoost
MAE (€)	0,9693	0,5624	-72,4%
MAPE (%)	10,75%	11,22%	+4,2%
RMSE (€)	11,8740	2,0841	-470%
R ²	0,3958	0,9814	-59,7%

XGBoost mejora el **error porcentual medio** (MAPE) en un +4,2% en los cambios reales, confirmando que captura señales genuinas de cambio. Sin embargo, el MAE es un 72,4%

peor y el RMSE significativamente más elevado, lo que indica que cuando XGBoost se equivoca, comete errores de gran magnitud concentrados en el segmento premium.

La divergencia entre MAE y RMSE apunta a un patrón claro: el modelo falla en los productos caros (rango 100-500 €), donde la magnitud del cambio es mayor y los datos de entrenamiento son más escasos. El 95% del catálogo tiene precios inferiores a 30 €, por lo que el modelo optimiza para ese segmento y carece de representatividad en el segmento premium.

C.4. Interpretabilidad: análisis SHAP

Se utiliza SHAP (*SHapley Additive exPlanations*) en lugar de la `feature_importances_` nativa de XGBoost por tres razones: no presenta sesgo hacia features de alta cardinalidad, descompone la contribución de cada feature por muestra individual, y es aditivo (las contribuciones suman la predicción final).

C.4.1. Importancia global

Posición	Feature	mean(SHAP)	Interpretación
1	precio_lag_1	1,15	Domina — el modelo esencialmente replica el precio del día anterior.
2	max_14d	0,36	El rango alto reciente ajusta la predicción al alza.
3	min_14d	0,31	El rango bajo reciente ajusta a la baja.
4	precio_lag_30	0,17	Contexto de precio hace un mes.
5	precio_por_medida	0,09	Nivel de precio unitario del producto.
...	...	...	...
9	`prob_cambio_lstm`	0,07	Señal del LSTM: aporta información predictiva.
...	...	...	...
15-21	dia_semana, mes, etc.	0,03 (total)	Estacionalidad: impacto negligible.

precio_lag_1 concentra el 53% del impacto SHAP medio total. Esto confirma cuantitativamente que el modelo aprende una versión sofisticada de la persistencia, corrigiéndola con el rango reciente (`max_14d`, `min_14d`).

Las features de calendario (`dia_semana`, `mes`) aparecen en el grupo residual con impacto negligible. Su escasa contribución es coherente con el dominio: Mercadona no ajusta precios siguiendo patrones semanales o mensuales predecibles, sino mediante decisiones comerciales puntuales.

C.4.2. Análisis beeswarm: impacto por valor de feature

La gráfica beeswarm revela tres patrones estructurales:

1. **Concentración en cero.** La inmensa mayoría de puntos se agrupan en torno a SHAP = 0 para todas las features. Esto es coherente con que el 95,9% de las muestras no cambian de precio: en esos casos, ninguna feature necesita «empujar» la predicción fuera de la persistencia.
2. **Outliers extremos en `min_14d`.** Los valores altos de `min_14d` alcanzan SHAP values de +80 €. Estos corresponden a productos caros cuyo precio mínimo reciente ya es elevado. Son los mismos casos donde el modelo comete los errores de RMSE más severos, confirmando que la dificultad se concentra en el segmento premium.
3. **Señal coherente de `prob_cambio_lstm`.** Los valores altos de probabilidad de cambio empujan la predicción hacia arriba, mientras que los bajos la empujan hacia abajo. Este patrón es **direccionalmente coherente**: cuando el LSTM predice cambio, XGBoost ajusta su predicción de precio en consecuencia.

C.4.3. Validación cruzada entre modelos: convergencia no planificada

La posición 9 de `prob_cambio_lstm` en el ranking SHAP constituye el hallazgo más original del módulo. Dos modelos entrenados de forma completamente independiente — un LSTM clasificador (Sprint 3) y un XGBoost regresor (Sprint 4) — convergen sobre la misma señal:

- El LSTM aprendió, a partir de secuencias temporales de 14 días, a identificar patrones que preceden a un cambio de precio.
- XGBoost, sin conocer la arquitectura ni los datos del LSTM, selecciona esa señal como la novena feature más informativa entre 21 candidatas.

Esta convergencia no planificada constituye una forma de validación cruzada entre modelos: si dos arquitecturas radicalmente distintas (red recurrente frente a ensemble de árboles) coinciden en que una señal es informativa, la confianza en dicha señal aumenta significativamente. La probabilidad del LSTM no solo aporta información predictiva al XGBoost, sino que el hecho de que XGBoost la valore como relevante valida retrospectivamente la calidad del clasificador LSTM.

C.5. Walk-forward validation

C.5.1. Diseño de la validación

En lugar de un único split entrenamiento/test, la walk-forward validation divide la línea temporal en 3 folds expansivos que simulan el funcionamiento del modelo en producción. El conjunto de entrenamiento crece acumulativamente en cada fold, emulando un reentrenamiento periódico:

Fold 1: train = [nov 2025 ... ene 2026] test = [ene ... feb 2026]
 Fold 2: train = [nov 2025 ... feb 2026] test = [feb ... mar 2026]
 Fold 3: train = [nov 2025 ... mar 2026] test = [mar ... may 2026]

C.5.2. Resultados por fold

Fold	Entrenamiento	Test	MAE (€)	RMSE (€)	R ²	MAPE (%)
1	275.940	91.086	0,0448	0,4283	0,9984	0,86%
2	367.026	90.568	0,1110	4,2096	0,8496	1,08%
3	457.594	90.126	0,1360	4,6879	0,8042	1,36%
Media	—	—	0,0973	3,1086	0,8841	1,10%

C.5.3. Degradación temporal: conexión con el Autoencoder de anomalías

El rendimiento se degrada significativamente entre folds: R² cae de 0,9984 a 0,8496 a 0,8042, y RMSE crece de 0,43 € a 4,21 € a 4,69 €. Esta degradación no es aleatoria, sino que tiene una explicación que conecta el módulo XGBoost con el módulo de detección de anomalías.

El modelo se entrena predominantemente con datos del período noviembre 2025 – marzo 2026, un período de estabilidad de precios. El test del tercer fold cae en abril-mayo de 2026, que coincide exactamente con el pico de anomalías detectado por el Autoencoder LSTM en el módulo de análisis de anomalías:

Fold	Período de test	Contexto del mercado	R ²
1	ene – feb 2026	Período estable	0,9984
2	feb – mar 2026	Transición	0,8496
3	mar – may 2026	Pico de anomalías	0,8042

El modelo nunca observó ese nivel de volatilidad durante el entrenamiento. Los dos módulos — XGBoost (predicción) y Autoencoder (anomalías) — llegan a la misma conclusión por caminos independientes: los patrones de precio de Mercadona cambiaron a partir de marzo-abril de 2026. Esta convergencia refuerza la narrativa de que los cambios de precio detectados como anómalos por el Autoencoder son genuinos y no artefactos del modelo.

C.6. Observaciones técnicas del entrenamiento

C.6.1. Convergencia por early stopping

El MAE de validación alcanzó su punto mínimo en la iteración 254 (MAE = 0,11394 €). El entrenamiento finalizó por early stopping en la iteración 274 al agotarse la paciencia de 20 épocas consecutivas sin mejora. Esto indica que el modelo convergió de forma óptima sin necesidad de agotar los 500 estimadores máximos configurados, previniendo el sobreajuste.

```
[ 0] validation_0-mae: 2,18180
[ 50] validation_0-mae: 0,25843
[100] validation_0-mae: 0,12472
[150] validation_0-mae: 0,11597
[200] validation_0-mae: 0,11473
[250] validation_0-mae: 0,11394
[274] validation_0-mae: 0,11397 ← early stopping
```

C.6.2. Hiperparámetros de regularización

Parámetro	Valor	Propósito
n_estimators	500	Máximo de árboles (limitado por early stopping).
learning_rate	0,05	Tasa de aprendizaje conservadora.
max_depth	6	Profundidad moderada — equilibrio entre complejidad y generalización.
subsample	0,8	Bagging: cada árbol entrena con el 80% de las muestras.
colsample_bytree	0,8	Feature bagging: cada árbol evalúa el 80% de las features.
min_child_weight	5	Mínimo de muestras por hoja — previene sobreajuste en hojas pequeñas.
reg_alpha	0,1	Regularización L1 (Lasso).
reg_lambda	1,0	Regularización L2 (Ridge).

Los hiperparámetros se seleccionaron por criterio experto y literatura de referencia. No se implementó búsqueda automatizada (Optuna, Random Search), lo que se reconoce como limitación y se propone como línea de mejora futura (sección 4.4 de la memoria).

C.7. Limitaciones del modelo

1. **Persistencia imbatible a nivel global.** En series con estructura de escalón, la predicción trivial `precio_mañana = precio_hoy` es casi óptima. XGBoost solo aporta valor marginal (+4,2% MAPE) en el 4,1% de casos donde sí se produce un cambio.
2. **Sesgo hacia productos baratos.** El 95% del catálogo tiene precios inferiores a 30 €. El modelo optimiza para ese segmento y comete errores severos en productos caros (rango 100-500 €), donde el RMSE se dispara hasta -350 € en los peores casos.
3. **Degradación temporal sin reentrenamiento.** El modelo entrenado con datos estables (noviembre-marzo) se degrada significativamente cuando los patrones de precio cambian (abril-mayo). Un sistema de producción requeriría reentrenamiento periódico con monitorización del R^2 en ventanas deslizantes.
4. **Features de calendario sin impacto.** Las variables `dia_semana` y `mes` no aportan señal predictiva en este dominio. Los cambios de precio de Mercadona son decisiones comerciales puntuales, no patrones estacionales predecibles.
5. **Ausencia de búsqueda de hiperparámetros.** Los hiperparámetros se fijaron por criterio experto. Una optimización automatizada podría mejorar el rendimiento, particularmente en el segmento de productos caros donde el modelo presenta las mayores debilidades.

C.8. Síntesis y contribuciones del módulo

El módulo XGBoost produce tres contribuciones al proyecto:

Cuantificación rigurosa del problema. La comparación con el baseline naive demuestra que los precios de Mercadona son extremadamente predecibles por persistencia — una propiedad fundamental del dominio de retail de precios fijos. El baseline de persistencia obtiene un MAE de 0,0230 € y un R^2 de 0,9984, siendo correcto el 95,9% del tiempo. Este resultado establece el techo de dificultad contra el cual cualquier modelo predictivo debe medirse.

Valor incremental en cambios reales. En el subconjunto donde sí ocurren cambios de precio (4,1% de las muestras), XGBoost mejora el MAPE en un +4,2% respecto al naive. Aunque la mejora es modesta, confirma que el modelo captura señales reales de cambio, particularmente a través de la integración de la probabilidad del LSTM.

Convergencia inter-modular. La integración de tres módulos independientes produce una narrativa coherente: el LSTM genera una señal que XGBoost valida como informativa (posición 9 de 21 en SHAP); el Autoencoder detecta anomalías en abril-mayo que explican la degradación temporal del XGBoost en walk-forward; y la combinación LSTM (detectar cuándo cambiará el precio) más XGBoost (estimar cuánto costará) constituye un sistema

complementario que aborda las dos facetas del problema de predicción de precios. Esta convergencia entre módulos diseñados de forma independiente constituye la contribución técnica más sólida del sistema de predicción.

ANEXO D. Análisis del clustering K-Means — perfiles de negocio

D.1. Diseño del pipeline de segmentación

El módulo de segmentación aplica K-Means sobre variables estadísticas derivadas del comportamiento de precios de cada producto, con el objetivo de descubrir arquetipos de negocio reales en el catálogo de Mercadona. A diferencia de los modelos supervisados del proyecto (LSTM, XGBoost), el clustering opera sin etiquetas: su valor reside en revelar patrones latentes que no son evidentes mediante inspección manual.

El pipeline sigue una secuencia de seis fases: carga del histórico, feature engineering (cálculo de estadísticos por producto), limpieza de outliers extremos, transformación logarítmica y escalado estándar, clustering K-Means, y proyección PCA para visualización y validación.

Decisiones de diseño clave

Decisión	Justificación
Estadísticos en lugar de serie temporal plana	Evita la «maldición de la dimensionalidad». Usar 154 columnas de días para K-Means generaría ruido; en su lugar se emplean 7 estadísticos descriptivos que resumen el comportamiento de precios de cada producto.
Eliminación del percentil 99 (outliers)	K-Means es extremadamente sensible a distancias euclidianas. Sin este filtro, el algoritmo agrupaba 1 solo producto de precio extremo en un cluster y los 5.041 restantes en otro, inutilizando la segmentación.
Transformación logarítmica (np.log1p)	Las variables financieras (<code>precio_medio</code> , <code>precio_std</code> , <code>rango_precio</code> , <code>variacion_media</code>) presentan fuerte asimetría positiva. El logaritmo normaliza la distribución, permitiendo que variables como <code>prop_estable</code> y <code>n_cambios</code> tengan peso real en la decisión del modelo.

Decisión	Justificación
K=5 sobre K=2 (Silhouette máximo)	Matemáticamente, el Silhouette Score sugería K=2 (0,77) para separar productos normales de extremos. A nivel de negocio, K=5 (Silhouette 0,441) obliga al algoritmo a descubrir perfiles funcionales accionables, sacrificando coherencia matemática marginal a favor del valor interpretativo.

D.2. Feature engineering

Se construyen 7 features estadísticas a partir del histórico de precios de cada producto:

Feature	Descripción
precio_medio	Precio medio del producto en todo el período.
precio_std	Desviación típica del precio — mide la dispersión absoluta.
rangoPrecio	Diferencia entre el precio máximo y mínimo observados.
n_cambios	Número total de cambios de precio en el histórico.
prop_estable	Proporción de días sin cambio de precio — mide la estabilidad.
variacion_media	Variación porcentual media cuando se produce un cambio.
es_marca_propia	Proporción de marca propia (0 o 1 por producto).

Antes del escalado estándar (StandardScaler), se aplica transformación logarítmica (`np.log1p`) a las cuatro variables con asimetría positiva: `precio_medio`, `precio_std`, `rangoPrecio` y `variacion_media`. Esto garantiza que las magnitudes absolutas de los precios no dominen la distancia euclidiana del algoritmo, permitiendo que la volatilidad y la estabilidad contribuyan equitativamente a la formación de clusters.

D.3. Proceso iterativo de refinamiento

El modelo pasó por cuatro iteraciones para resolver un colapso matemático inicial donde los productos extremos dominaban el espacio de distancias.

Iteración 1: entrenamiento crudo

Cluster 0: 5.041 productos
Cluster 1: 1 producto

El algoritmo detectó correctamente un outlier extremo, pero fracasó en segmentar el catálogo. El Silhouette Score resultaba casi perfecto (0,987), pero a nivel de negocio el resultado era inútil: no se diferenciaba ningún perfil de comportamiento.

Iteración 2: eliminación de outliers (percentil 99)

Se eliminaron los 52 productos más caros del catálogo. El modelo comenzó a dividir el bloque masivo en subgrupos, pero las variables con fuerte asimetría seguían dominando la formación de clusters.

Iteración 3: transformación logarítmica

La normalización logarítmica de las variables asimétricas permitió que `prop_estable` y `n_cambios` adquirieran peso real en la decisión del modelo, sin ser eclipsadas por la magnitud de los precios absolutos.

Iteración 4: selección de K=5 (versión final)

Cluster 0: 1.467 productos
Cluster 1: 120 productos
Cluster 2: 2.942 productos
Cluster 3: 30 productos
Cluster 4: 490 productos

Se forzó K=5 por criterio de negocio, coincidiendo con el punto de inflexión del método del codo (inercia). El resultado produce cinco perfiles diferenciados y accionables.

D.4. Métricas globales del modelo

Métrica	Valor
Productos totales analizados	5.049
Outliers extremos eliminados (percentil 99)	52
Productos segmentados	4.997
Número de features	7
Número de clusters (K)	5

Métrica	Valor
Silhouette Score (K=5)	0,441
Varianza explicada PCA 2D	76,0%
PC1 (varianza)	48,1%
PC2 (varianza)	27,9%

Una varianza explicada del 76,0% en solo dos componentes principales garantiza que la proyección visual representa fielmente las distancias reales de los grupos en el espacio de 7 dimensiones. Las posiciones relativas observadas en la proyección PCA no son artefactos de la reducción de dimensionalidad.

D.5. Perfiles de negocio descubiertos

La segmentación final arroja cinco arquetipos con perfiles diferenciados:

D.5.1. Cluster 3 — Frescos de Alta Volatilidad (30 productos)

Característica	Valor
Tamaño	30 productos
Marca propia	0%
Cambios de precio (media)	89
Estabilidad	41,8%
Categorías dominantes	Fruta y verdura, marisco y pescado

Este cluster captura los productos de lonja y frescos cuyo precio fluctúa casi a diario por la dinámica mayorista. Son productos genéricos de mercado (0% marca propia) cuyo precio depende de la oferta y la demanda del día. En la proyección PCA, aparecen drásticamente separados del bloque central debido a su extrema frecuencia de cambios.

D.5.2. Cluster 2 — Básicos Estables de Marca Blanca (2.942 productos)

Característica	Valor
Tamaño	2.942 productos

Característica	Valor
Marca propia	77,4%
Cambios de precio (media)	~1
Estabilidad	99,8%
Categorías dominantes	Cuidado facial y corporal, limpieza y hogar, charcutería y quesos

El bloque mayoritario del catálogo: commodities esenciales donde el supermercado fija el precio como estrategia de anclaje mental para el consumidor. Su estabilidad del 99,8% los convierte en el componente que hace que el baseline naive sea casi imbatible en el módulo de predicción (Anexo C). En el silhouette plot, estos productos presentan puntuaciones que superan holgadamente la media (0,44), rozando valores de 0,6, lo que indica un anclaje excelente a su centroide.

D.5.3. Cluster 1 — Marcas Nacionales en Promoción (120 productos)

Característica	Valor
Tamaño	120 productos
Marca propia	10,8%
Precio medio	Medio-alto
Desviación típica del precio	Alta
Categorías dominantes	Cuidado facial y corporal, bodega

Productos premium de marcas comerciales que experimentan campañas agresivas de marketing, generando grandes escalones de precio (rebajas y subidas) que el algoritmo detecta a través del rango_precio. La baja proporción de marca propia (10,8%) confirma que son fundamentalmente marcas nacionales cuya estrategia de pricing incluye promociones periódicas.

D.5.4. Cluster 4 — Dinámicos de Variabilidad Moderada (490 productos)

Característica	Valor
Tamaño	490 productos

Característica	Valor
Marca propia	26,7%
Cambios de precio (media)	~4,9
Estabilidad	96,2%
Composición	Mixta (marca propia y comercial)

Productos que sufren ajustes por inflación, temporada o costes logísticos, pero sin la volatilidad extrema de los frescos del Cluster 3. En el silhouette plot, este cluster presenta una pequeña cola de puntuaciones negativas, lo que es normal en clustering real: los productos de variabilidad moderada tienen puntos fronterizos que se solapan geoméricamente con los clusters estables o los más volátiles, creando una transición fluida en lugar de una frontera rígida.

D.5.5. Cluster 0 — Estables de Precio Medio (1.467 productos)

Característica	Valor
Tamaño	1.467 productos
Marca propia	58,6%
Estabilidad	99,8%
Precio medio	Superior al Cluster 2

Comparte la estabilidad monolítica del Cluster 2 (99,8%), pero se diferencia por un precio base significativamente superior y una menor dominancia de marca propia (58,6% frente a 77,4%). En la proyección PCA, ambos clusters forman una nube compacta a la izquierda del gráfico, pero se separan a lo largo del eje del precio medio.

D.6. Diagnóstico visual

D.6.1. Método del codo y Silhouette Score

El método del codo muestra una caída pronunciada de inercia desde K=2 hasta K=4, y a partir de K=5 la curva se suaviza significativamente. Esto confirma empíricamente que K=5 se sitúa en el punto de inflexión real de la distribución. El Silhouette Score es matemáticamente máximo en K=2 (0,77), resultado habitual en distribuciones con asimetría donde el modelo simplemente separa «lo masivo» de «los extremos». El score se estabiliza en torno a 0,44 para K=5 a K=8, indicando que nos encontramos dentro de un rango de segmentación válido donde el aumento de clusters no degrada la calidad.

D.6.2. Proyección PCA 2D

La proyección bidimensional revela una estructura espacial coherente con los perfiles de negocio:

- **Foco central (Clusters 2 y 0).** A la izquierda se observa una nube compacta formada por los clusters masivos de productos estables, reflejo de su variabilidad casi nula.
- **Extremo de volatilidad (Cluster 3).** Arriba a la derecha, muy alejado del bloque central, se distingue el cluster de frescos. El PCA lo separa drásticamente debido a la extrema frecuencia de cambios de precio diarios.
- **Nubes de transición (Clusters 4 y 1).** Actúan como puentes entre el bloque estable y el extremo volátil. El cluster de variabilidad moderada y el de marcas en promoción se separan de forma clara y coherente en las dimensiones reducidas.

D.6.3. Silhouette plot

El silhouette plot confirma la estructura de los clusters:

- Los clusters mayoritarios (2 y 0) presentan siluetas gruesas donde gran parte de la distribución supera la media (0,44), con valores que alcanzan 0,6. Los productos estables están bien anclados a sus centroides.
- El cluster 3 (frescos) forma una franja delgada por su escaso volumen (30 productos), pero se extiende sorprendentemente hacia la derecha, confirmando que su comportamiento es suficientemente único para justificar un grupo independiente.
- El cluster 4 (dinámicos) muestra la cola de puntuaciones negativas esperada en los puntos fronterizos de un clustering real.

D.7. Conexiones inter-modulares

Los perfiles descubiertos por K-Means se conectan con los hallazgos de otros módulos del proyecto:

Cluster	Conexión con otros módulos
Cluster 3 (frescos)	Los 30 productos frescos corresponden a las categorías con más anomalías en Z-Score Rolling (fruta y verdura: 705 alertas) y con la totalidad de los casos de shrinkflation detectados (20 alertas, 100% producto fresco).
Cluster 2 (básicos estables)	Su estabilidad del 99,8% es el factor que hace que el baseline naive sea casi imbatible en el XGBoost ($R^2 = 0,9984$). Este cluster representa la «masa estable» que domina las métricas globales de predicción.

Cluster	Conexión con otros módulos
Cluster 1 (marcas en promoción)	Los 120 productos con alto rango de precio se alinean con los productos que el Autoencoder LSTM detecta como secuencias anómalas: rupturas en el patrón estable aprendido.
Cluster 4 (dinámicos)	Los ~4,9 cambios de media por producto generan las señales de cambio que el LSTM clasificador intenta predecir (AUC-ROC 0,893).

D.8. Limitaciones del modelo

1. **Sesgo por geometría esférica.** K-Means asume distancias euclidianas y clusters esféricos. Esto puede forzar divisiones artificiales en distribuciones alargadas, aunque la proyección PCA demuestra una separación razonablemente limpia en este caso.
2. **Dependencia de la ventana temporal.** Las variables de volatilidad (`n_cambios`, `prop_estable`) dependen directamente de la ventana de 154 días analizada. En periodos macroeconómicos muy estables, los perfiles de los clusters 4 y 1 podrían fusionarse al no haber suficientes cambios para diferenciarlos.
3. **Outliers excluidos sin análisis.** Los 52 productos del percentil 99 eliminados antes del clustering no se analizaron individualmente. Estos coinciden parcialmente con los 59 productos detectados por Isolation Forest (Anexo A), que representan productos premium estructuralmente raros (jamón ibérico de bellota, cochinillo).
4. **Selección manual de K.** Se forzó K=5 por criterio de negocio sin explorar alternativas como DBSCAN o clustering jerárquico, que podrían descubrir estructuras no esféricas o un número natural de clusters sin necesidad de fijarlo manualmente.

D.9. Síntesis y conclusión

El pipeline de segmentación transforma el catálogo de una lista plana de 5.049 productos en cinco arquetipos de negocio accionables:

Cluster	Perfil	Productos	Marca propia	Estabilidad
3	Frescos de alta volatilidad	30	0%	41,8%
1	Marcas nacionales en promoción	120	10,8%	Variable

Cluster	Perfil	Productos	Marca propia	Estabilidad
4	Dinámicos de variabilidad moderada	490	26,7%	96,2%
0	Estables de precio medio	1.467	58,6%	99,8%
2	Básicos estables de marca blanca	2.942	77,4%	99,8%

La tabla, ordenada por estabilidad creciente, revela un gradiente continuo desde la volatilidad extrema de los frescos hasta la estabilidad monolítica de los básicos de marca blanca. Este gradiente no fue diseñado explícitamente, sino que emergió de forma natural del algoritmo, lo que constituye una validación de la calidad del feature engineering aplicado.

El valor del módulo reside en el paso del análisis descriptivo al descubrimiento de conocimiento: se ha pasado de «saber los precios» a «entender el comportamiento de los precios». Identificar de forma automatizada qué artículos forman la cesta ancla (estables), cuáles se usan como ganchos promocionales (marcas nacionales) y cuáles dictan el mercado diario (frescos) dota al sistema de una capacidad de inteligencia competitiva complementaria al resto de módulos del proyecto.