



TITULACIÓN: Máster de FP en Inteligencia Artificial y Big Data.

CURSO: Curso de Especialización en Inteligencia Artificial y Big Data

Nombre y apellidos de los componentes y rol dentro del proyecto:

Nombre y Apellidos	Rol
Daniel Porras Morales	Desarrollador / Investigador

Nombre y apellidos del Tutor responsable de revisar memoria y presentación:

Pendiente de asignación

1. Título del Proyecto:

MercaIntelligence: Sistema de análisis, predicción y detección de anomalías de precios sobre el catálogo de Mercadona mediante Big Data y Machine Learning

2. Objetivos:

Objetivo general:

Desarrollar un sistema integral de Big Data y Machine Learning capaz de recopilar, almacenar, procesar y analizar la evolución diaria de precios del catálogo de Mercadona, extrayendo valor mediante detección de anomalías, predicción temporal, análisis semántico de productos y visualización interactiva en tiempo real.

Objetivos específicos:

1. Construir un pipeline ETL incremental que ingeste automáticamente el CSV diario generado por el scraper (GitHub Actions) y lo consolide en un repositorio Parquet e indexe en Elasticsearch.

2. Implementar y comparar tres métodos de detección de anomalías de precios (Z-Score rolling, Isolation Forest y Autoencoder), evaluando su precisión y cobertura sobre datos reales.
3. Desarrollar un modelo LSTM para la predicción de cambios de precio a n° días, comparando su rendimiento frente a una línea base de regresión logística.
4. Aplicar embeddings semánticos con modelos de lenguaje (sentence-transformers multilingüe) para identificar automáticamente equivalencias entre productos de marca blanca (Hacendado) y marcas comerciales.
5. Construir un índice de precios personalizado (IPC propio) y exponerlo mediante una API Flask, permitiendo al usuario simular su cesta de la compra y visualizar su evolución temporal.
6. Diseñar y desplegar cuatro dashboards en Kibana que visualicen en tiempo real la evolución de precios, alertas de anomalías, brechas entre marcas y el índice de precios personalizado.

3. Propuesta de índice o estructura del Proyecto:

1. Introducción y justificación del proyecto

- 1.1 Contexto y motivación
- 1.2 Objetivos
- 1.3 Alcance y limitaciones
- 1.4 Metodología (SCRUM)

2. Estado del arte y marco teórico

- 2.1 Web scraping y automatización
- 2.2 Series temporales en retail
- 2.3 Detección de anomalías
- 2.4 Modelos LSTM
- 2.5 NLP y embeddings semánticos

3. Diseño del sistema

- 3.1 Arquitectura general (pipeline scraping→ETL→almacenamiento→ML→visualización)
- 3.2 Modelo de datos
- 3.3 Diseño del pipeline incremental
- 3.4 Selección y justificación de tecnologías

4. Desarrollo e implementación

- 4.1 Sprint 1: ETL y almacenamiento
- 4.2 Sprint 2: Módulo de anomalías
- 4.3 Sprint 3: LSTM y NLP/embeddings



4.4 Sprint 4: IPC, clustering y despliegue

5. Evaluación de modelos y resultados

5.1 Comparativa de métodos de detección de anomalías

5.2 Evaluación del LSTM vs. baseline

5.3 Análisis de embeddings semánticos

5.4 Dashboards y visualización

6. Conclusiones, líneas futuras y referencias

4. Fuentes de datos

Fuente principal — Catálogo público de Mercadona (tienda.mercadona.es):

Scraper automatizado diariamente mediante GitHub Actions. Genera un fichero CSV por día con ~4.360 productos.

Campos capturados: referencia, título, categoría, subcategoría, formato, precio_actual, precio_anterior, precio_por_medida, unidad_medida, timestamp. Actualmente se dispone de 148 snapshots históricos (desde noviembre 2024).

Fuente de referencia externa — INE (Instituto Nacional de Estadística):

Datos públicos del Índice de Precios al Consumo (IPC) mensual por categoría de alimentos. Utilizados para contextualizar y validar el índice personalizado calculado sobre los datos de Mercadona.

5. Calendario de trabajo hasta la entrega final/Hitos

Sprint 1 (Semana 1) — ETL y almacenamiento:

Consolidación de los 148 CSVs históricos en Parquet maestro. Desarrollo de ingesta_incremental.py con watchdog. Despliegue de Elasticsearch + Kibana vía Docker Compose. Primer dashboard de evolución de precios. Hito: pipeline funcional extremo a extremo.

Sprint 2 (Semana 2) — Módulo de detección de anomalías:

Implementación de Z-Score rolling (baseline), Isolation Forest y Autoencoder (Keras). Comparativa de los tres métodos. Dashboard de alertas en Kibana. Hito: notebook de anomalías con tabla comparativa de métodos.

Sprint 3 (Semana 3) — Deep Learning y NLP:

Modelo LSTM (clasificación binaria de cambio en 7 días) con comparativa frente a Logistic Regression. Embeddings semánticos con sentence-transformers para detección de equivalencias Hacendado/comercial. API Flask con IPC personalizado. Hito: demo Flask operativa.

Sprint 4 (Semana 4) — Integración, evaluación y documentación:

Clustering K-Means sobre series temporales de precio. Finalización de los 4 dashboards Kibana. Cierre de la memoria (diseño, desarrollo, evaluación). Preparación de la presentación final. Hito: entrega completa del proyecto.

Fecha: 24 de abril de 2026